

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

```
## 열 이름으로 선택
flights['dest'] # -> Series
flights[['dest']] # -> DataFrame
flights[['origin', 'dest']] # 두개 이상 칼럼 선택 할때는 리스트 형태로 [] 한번더 감싸야 함

## 행 선택
flights[2:5] # 슬라이싱(위치 인덱스) : 범위의 끝 제외 (인덱스 2번부터 4번까지 행 가져오기)

flights[['origin', 'dest']][2:5] # df 잘라서 보기
```

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

- 데이터를 전처리하고 집계하는 능력

.loc[행,열]: 라벨 이름으로 인덱싱

flights.loc[2:5, ['origin', 'dest']] # 2:5는 행의 인덱스 명! 범위의 끝 포함!

df_outoforder.loc[[25, 33], :] # slicing이 아닌 특정 index 선택, ':' 는 모든걸 선택한다는거

.iloc[행,열]: 정수형 위치 인덱스로 인덱싱

flights.iloc[2:5, 12:14] # 2:5는 행의 위치 인덱스! 범위의 끝 미포함!

flights.iloc[[2, 5, 7], 12:14] # 특정 위치의 rows 선택

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

- 필터링 : [], loc 이용 (Boolean indexing)

Q. 'dep_delay' 열의 값이 0 미만인 행의 'dest' 열을 출력하라

Bracket [] 을 이용하는 방법

```
idx = flights["dep_delay"] < 0    # 0 미만이면 TRUE 라는 시리즈 반환  
flights[idx]["dest"]              # true로 인덱싱 된 것만 가져옴
```

loc 을 이용하는 방법

```
flights.loc[idx, "dest"]           # flights_6[idx]["dest"]과 동일  
flights.loc[flights["dep_delay"] < 0, "dest"] # 아예 한꺼번에 넣어도 OK.
```

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

- `np.where(조건, 조건이 참일때 값, 조건이 거짓일때 값)` : 조건에 해당하거나 해당하지 않을 경우에 특정 값들을 갖게 하고 싶을때

```
## Q. 'dep_delay' 열의 값이 0 초과인 행은 'delayed', 이하인 행은 'on-time'의 값을  
가지는 'delayed' 열을 추가해라  
import numpy as np  
idx = flights["dep_delay"] > 0  
flights["delayed"] = np.where(idx, "delayed", "on-time")
```

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

보스턴 집값 데이터 로드 (/datasets/201_boston.csv)
CRIM 기준 내림차순 정렬
CRIM 상위 10개 행의 값을 10번째 CRIM 값으로 모두 변경
변경된 전체 데이터에서 $AGE \geq 80$ 인 행 추출
추출된 데이터의 CRIM 평균 계산
결과 출력

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

202_housing.csv 데이터의 첫번째 행 부터 순서대로 80%까지의 데이터를 추출 후 'total_bedrooms' 변수의 결측값(NA)을 'total_bedrooms' 변수의 중앙값으로 대체하고 대체 전의 'total_bedrooms' 변수 표준편차값과 대체 후의 'total_bedrooms' 변수 표준편차의 차이(절댓값)를 출력하시오

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

203_housing.csv 데이터의 population 변수에 대해 이상치를 구하고 이상치의 합계를 출력하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

301_housing.csv 데이터의 결측치를 제거한 후, 데이터의 앞쪽 70%를 추출하여 housing_median_age 변수의 제1사분위수(Q1, 25% 분위수)를 출력하시오

데이터 분석

- 1유형 - 데이터를 전처리하고 집계하는 능력

WorldData 데이터에서 2000년 데이터만 추출한 후, 각 국가(또는 변수)의 값 중 2000년 전체 평균보다 큰 값의 개수를 구하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

Titanic 데이터에서 각 변수의 결측치 개수를 구하고, 결측치가 가장 많은 변수명을 출력하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

Facebook 게시물 중 긍정 반응 비율($(\text{좋아요} + \text{와우}) / \text{전체 반응}$)이 40% 초과 50% 미만인 비디오 게시물의 개수를 계산 출력하시오

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

Netflix 데이터에서 2018년 1월(January 2018)에 추가된 콘텐츠 중 국가(country)가 United Kingdom인 콘텐츠의 개수를 구하시오

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

종량제 봉투 데이터에서 용도가 음식물쓰레기이고 사용대상이 가정용인 데이터를 추출한 후,
2L 가격이 0이 아닌 데이터만 선택하여 2L 가격의 평균을 구하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

신장(Height)과 체중(Weight)을 이용해 BMI를 계산한 후, 정상 체중($18.5 \leq \text{BMI} < 23$)인원수와 과체중($23 \leq \text{BMI} < 25$)인원수의 차이(절댓값)를 구하시오

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

학생 데이터에서 순 전입학생 수(총 전입학생 - 총 전출학생)를 계산한 후, 가장 순유입이 많은 학교를 찾고, 그 학교의 전체 학생 수를 출력하시오

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

데이터 세트는 소방서별 신고접수시간, 출발시간, 도착시간이다. 신고접수 후 출발시간까지를 대응시간, 출발시간에서 도착시간까지를 출동시간이라 한다. 소방서별 출동시간 평균이 가장 큰 소방서의 출동시간 평균을 구하시오. (소수 둘째자리 반올림)

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

초등학교 학년별 학생수와 교사수 데이터 세트로부터 교사 1인당 학생 수가 가장 많은 학교를 찾은 후 그 학교의 전체 학생수를 구하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

경찰서별 월별 발생한 범죄 데이터 세트이다. 2021년 대비 2022년의 범죄가 가장 많이 늘어난 경찰서(Police Station)의 2021년 교통범죄(Traffic Crimes)건수를 구하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

학생들의 과목별 점수 데이터 세트이다
수강과목은 통계(Statistics), 데이터사이언스(DataScience), 머신러닝(MachineLearning), 교양영어(EnglishLiterature) 이다. 학생들은 이중 3과목을 선택하여 들었으며 이에 대한 점수를 받았다. 가장 많은 학생이 들었던 과목을 구하고 결측치를 제거한 후, 해당 과목의 점수를 표준화하여 가장 높은 점수를 소수 둘째 자리로 반올림하여 구하라.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

데이터 세트는 물고기 데이터로 무게(Weight), 길이(Length), 높이(Height), 폭(Width), 지느러미크기(FinSize)로 구성되어 있다.
종속변수는 무게이며 나머지는 독립변수다. 종속변수와 가장 높은 상관관계를 보이는 독립변수를 찾으시오.

`idxmax()` : 최대값을 가지는 인덱스(행 이름) 를 반환

`corr()` : 상관계수(Correlation Coefficient) 를 계산

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

아파트 가격 데이터 세트는 아파트 가격을 결정하는 10개의 독립변수와 1개의 종속변수가 있다.

각 독립변수의 이상치를 사분위수를 기준으로 측정하고 이상치가 가장 많은 독립변수를 구하시오. 이때 결측치를 먼저 제거한 후 이상치를 구하시오.

(이상치는 $(1Q - 1.5IQR)$ 보다 작거나 $(3Q + 1.5IQR)$ 보다 큰 값이며, IQR은 Q3에서 Q1을 뺀 값임)

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

- 다음은 나라별 커피 원두 소비량에 대한 데이터다. 각 나라의 커피 원두 소비량과 대륙명 등을 포함한 데이터입니다

변수명	설명	변수 유형
country	나라 이름	범주형
continent	대륙명	범주형
Arabica_consumption	Arabica 원두 소비량 (kg)	수치형
Robusta_consumption	Robusta 원두 소비량 (kg)	수치형
Liberica_consumption	Liberica 원두 소비량 (kg)	수치형
Excelsa_consumption	Excelsa 원두 소비량 (kg)	수치형
Geisha_consumption	Geisha 원두 소비량 (kg)	수치형

- 1) 대륙별 평균 Arabica 원두 소비량이 가장 많은 대륙을 구하시오.
- (2) 1)에서 구한 대륙에서 다섯 번째로 Arabica 원두 소비량이 많은 나라를 구하시오.
- (3) 2)에 해당하는 나라의 Arabica 원두 소비량을 정수로 작성하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

각 나라별 자동차 판매량에 대한 데이터다. SUV 판매 비율이 세 번째로 높은 나라의 세단 판매량과 세단 판매량이 네 번째로 높은 나라의 SUV 판매량을 합한 값을 구하시오.

변수명	설명	변수 유형
country	나라 이름	범주형
sedan_sales	세단 판매량 (천대)	수치형
suv_sales	SUV 판매량 (천대)	수치형
total_sales	총 판매량 (천대)	수치형

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

데이터는 A 화학 공장의 생산 공정 중 원재료에 포함된 탄소 농도(Co)에 따른 설비의 성능 지표(Nmch)를 나타내는 값이다.

Co: 원재료에 포함된 탄소 농도

Nmch: 설비의 성능 지표 (예: 기계의 작업량, 에너지 소비량, 기계의 효율성 등)

(1) Co와 Nmch에 대해 최대-최소 정규화를 수행한 후, 각 칼럼의 표준 편차를 구하고 두 표준편차의 차이를 구하시오.

(2) 두 변수 중 변동성이 큰 변수는 무엇인지 답하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

고객의 금융거래 데이터

변수명	설명	변수 유형
customer_id	고객번호	범주형
age_group	연령층	범주형
p_bank_loan	p은행 대출금액	수치형
s_bank_loan	s은행 대출금액	수치형

- (1) 연령층(청년, 중년, 장년)에 따른 (p은행대출, s은행대출) 금액의 평균을 출력하시오.
- (2) 각 연령층별 두 은행의 대출금액 차이($|p\text{은행대출} - s\text{은행대출}|$)를 구하고, 대출금액 차이가 가장 큰 연령층을 출력하시오.
- (3) 대출금액 차이가 가장 큰 연령층에서 두 은행의 대출금액 차이가 가장 작은 고객의 고객번호를 출력하시오

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

범죄에 대한 데이터

변수명	설명	변수 유형
quarter	분기	범주형
crime_type	범죄유형	범주형
incidents	발생건수	수치형
arrests	검거건수	수치형

- 1) (분기, 범죄유형)별로 검거율을 구한 후, 가장 마지막 분기의 검거율이 가장 높은 범죄유형을 출력하시오. (검거율 = 검거건수/발생건수 * 100)
- (2) 1번에서 확인된 범죄유형의 검거건수 총합을 출력하시오.

데이터 분석

■ 1유형 - 데이터를 전처리하고 집계하는 능력

직원 데이터(employee_data.csv)의 결측값을 다음 조건에 따라 처리한 후, 아래 질문에 답하시오.

training_score의 결측값은 해당 부서의 중앙값으로 대체

years_of_service의 결측값은 성과등급별 근속연수의 평균값으로 대체 (평균값 계산 시 소수점 이하 올림)

(1) 연봉/근속연수(salary/years_of_service) 기준 상위 3번째 직원의 근속연수를 출력하시오.

(2) 연봉/교육점수(salary/training_score) 기준 상위 5번째 직원의 교육점수와 해당 직원의 부서를 출력하시오.