

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

1. 데이터 탐색 및 전처리
2. 데이터 분할
3. 인코딩
4. 스케일링
5. 머신러닝 모델 생성
6. 예측
7. 평가

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

데이터 확인	<code>df.head()</code> <code>df.tail()</code> <code>df.shape</code> <code>df.info()</code> <code>df.describe()</code>
결측치 확인 및 처리	<code>df.isnull().sum()</code> <code>df.fillna()</code> <code>df.dropna()</code>
이상치 확인	<code>df['col'].quantile()</code> <code>Q1 = df['col'].quantile(0.25)</code> <code>Q3 = df['col'].quantile(0.75)</code> <code>IQR = Q3 - Q1</code>
상관관계	<code>df.corr(numeric_only=True)</code>
데이터 분할	<code>from sklearn.model_selection import train_test_split</code> <code>X_train, X_valid, y_train, y_valid = train_test_split(</code> <code> X, y, test_size=0.2, random_state=42)</code>

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

인코딩	<pre>from sklearn.preprocessing import LabelEncoder le = LabelEncoder() le.fit() le.transform() le.fit_transform() le.inverse_transform() from sklearn.preprocessing import OneHotEncoder fit() transform() fit_transform() pandas의 get_dummies()</pre>
스케일링	<pre>from sklearn.preprocessing import StandardScaler scaler = StandardScaler() X_train = scaler.fit_transform(X_train) X_valid = scaler.transform(X_valid) from sklearn.preprocessing import MinMaxScaler from sklearn.preprocessing import RobustScaler</pre>

데이터 분석

- 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가
 - 분류 분석 평가 지표

Accuracy (정확도)	accuracy_score(y_true, y_pred)
F1 Score	F1 Scoref1_score(y_true, y_pred)
Precision (정밀도)	precision_score(y_true, y_pred) 실제 Negative인데, Positive로 잘못 예측 (건강한 사람을 암이라고 진단)
Recall (재현율)	recall_score(y_true, y_pred) 실제 Positive인데, Negative로 잘못 예측 (암 환자를 건강하다고 판단)
ROC-AUC	roc_auc_score(y_true, y_pred_proba[:,1]) 분류에서 확률 예측 시
classification_report	Precision, Recall, F1, Support를 클래스별로 한 번에 출력

데이터 분석

- 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가
 - 분류 분석 평가 지표

예측	<code>predict()</code>
평가 MAE	<code>from sklearn.metrics import mean_absolute_error</code>
평가 MSE	<code>from sklearn.metrics import mean_squared_error</code>
평가 RMSE	<code>import numpy as np</code> <code>rmse = np.sqrt(</code> <code>mean_squared_error(y_valid, pred)</code> <code>)</code>
R ² Score	<code>from sklearn.metrics import r2_score</code>

데이터 분석

- 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가
 - 분류 분석 모델 하이퍼 파라미터

랜덤포레스트(Random Forest Classifier)	
n_estimators	생성할 결정트리(Tree)의 개수 값이 클수록 예측 성능이 안정되는 경향
max_depth	각 결정트리의 최대 깊이 깊이가 깊을수록 복잡한 패턴을 학습
min_samples_split	노드를 분할하기 위해 필요한 최소 샘플 수 값이 크면 트리가 단순해져 과적합 감소
max_features	각 노드에서 분할 시 고려할 최대 특성(feature)의 개수 작은 값을 사용하면 트리 간 다양성이 증가하여 일반화 성능 향상 큰 값을 사용하면 각 트리의 성능은 높아질 수 있으나 다양성이 감소

데이터 분석

- 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가
 - 분류 분석 모델 하이퍼 파라미터

XGBoost Classifier	
n_estimators	부스팅(Boosting) 반복 횟수(생성할 트리의 수) 많을수록 성능 향상 가능 너무 많으면 과적합 및 학습 시간 증가
learning_rate	각 트리가 이전 오차를 얼마나 반영할지 결정하는 학습률 작을수록 안정적인 학습
max_depth	각 트리의 최대 깊이 클수록 복잡한 모델 생성
subsample	각 트리를 학습할 때 사용할 데이터의 비율 1.0이면 전체 데이터 사용 0.6~0.9 정도를 사용하면 과적합을 줄이는 데 도움이 될 수 있음

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

고객의 신용등급(09.02.train.csv , 09.02.test_x.csv)에 따라서 대출 실행 여부 및 이자율을 차등 적용할 계획이다. 주어진 훈련 데이터 세트를 활용하여 고객의 신용등급(credit_rating)을 분류하는 모델을 구축한 후 테스트 데이터를 대상으로 분류 결과를 csv 파일로 제출하시오. (채점 기준 – macro-f1 score)

변수명	설명	변수 유형
customer_id	고객 ID	범주형 (Categorical)
income	소득수준 (만원)	연속형 (Continuous)
debt_ratio	부채비율	연속형 (Continuous)
payment_delay	연체횟수	이산형 (Discrete)
credit_card_count	신용카드 개수	이산형 (Discrete)
loan_count	대출 건수	이산형 (Discrete)
property_value	부동산가치 (만원)	연속형 (Continuous)
age	나이	이산형 (Discrete)
education_level	학력수준	범주형 (Categorical)
employment_years	근속년수	이산형 (Discrete)
existing_loan_cnt	기존 대출 수	이산형 (Discrete)
credit_inquiry_cnt	신용조회수	이산형 (Discrete)
previous_default	과거 채무불이행 여부 (0: 없음, 1: 있음)	범주형 (Categorical)
loan_type	대출종류	범주형 (Categorical)
credit_history	신용거래기간 (개월)	이산형 (Discrete)
credit_rating	신용등급 (1, 2, 3)	범주형 (Categorical)

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

서울시에서 지하철역의 운영 효율성을 높이기 위해 각 역의 이용객 수를 예측하는 모델을 구축하려고 한다. 주어진 데이터 08.02.01.subway_train.csv)를 바탕으로 지하철역의 이용객 수(num_people)를 예측하는 머신러닝 모델을 만들어, 이를 바탕으로 각 지하철역의 자원 배분 및 운영 계획을 수립할 예정이다. 주어진 훈련 데이터 세트를 활용하여 지하철역 이용객 수 예측 모델을 구축한 후, 테스트 데이터를 대상으로 예측 결과를 csv 파일로 제출하시오. (채점기준 - RMSE)

변수명	설명	변수 유형
date	날짜	수치형
day_of_week	요일	범주형
month	월	수치형
station_name	지하철 역 이름	범주형
visibility	가시거리 (단위: km)	수치형
precipitation	강수량 (단위: mm)	수치형
temperature	온도 (단위: °C)	수치형
num_people	해당 지하철역의 이용객 수	수치형

데이터 분석

- 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

- 회귀 분석 머신러닝 클래스

```
from sklearn.linear_model import LinearRegression
```

```
from sklearn.ensemble import RandomForestRegressor
```

```
from sklearn.ensemble import GradientBoostingRegressor
```

```
from xgboost import XGBRegressor
```

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

회사에서 신규 영업지점을 설립하려고 한다. 기존 영업지점 데이터(07.02.01-sales_train_dataset.csv)를 이용하여 신규 영업지점을 설립할 경우 달성 가능한 매출을 예측하여 의사결정에 사용할 계획이다. 주어진 훈련 데이터 세트를 활용하여 매출 예측 머신러닝 모델을 구축하고, 테스트 데이터를 대상으로 매출을 예측한 결과를 csv 파일로 제출하시오.

변수	설명
BranchName	지점이름
City	지역
Population	지역 인구
IncomeGeneratingPopRatio	소득창출 인구비율
AverageIncome	지역 평균 소득
IndustryType	지역산업 종류
Sales	매출

표 3 : 지점매출 데이터 세트 변수 설명

데이터 분석

- 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

BranchName	Sales
지점1	
지점2	
...	

표 2 : 결과 제출 양식

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

다음은 선호하는 메타버스 유형에 대한 데이터 세트(06.02.01-Metaverse Training Data.csv)다. 주어진 훈련 데이터 세트를 활용하여 선호하는 메타버스 유형을 분류하는 모델을 구축하고 테스트 데이터 세트를 대상으로 분류한 결과를 csv 파일로 제출하시오.

변수	설명
id	번호
Gender	성 (male, female, other)
education	교육정도
Occupation Type	인더스트리
Residence Type	주거형태
Experience Using Metaverse	메타버스 사용 경험 유무
Age	연령
Annual Salary	연봉
Preferred Metaverse Type	메타버스타입 (0,1,2,3) 0 - Virtual world / 1 - Mirror world / 2 - Lifelogging / 3 - Augmented reality

표 5 : Metaverse 데이터 세트 변수 설명

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

id	Preferred Metaverse Type
1	0
2	1
3	2
...	3

표 4 : 결과 제출 양식

분류 모델 추천 알고리즘 클래스 :

[RandomForestClassifier](#) : 스케일링 불필요, 과적합이 상대적으로 적음, 안정적,
데이터가 복잡하면 성능 한계 존재

[XGBoost](#)

[LightGBM](#)

데이터 분석

■ 2유형 - 예측 모델을 만들고 결과를 생성하는 능력을 평가

주어진 차량 특성 데이터를 바탕으로 중고차 가격을 예측할 수 있는 회귀 모델을 구축하시오

학습용 데이터를 활용하여 모델을 학습하고, 평가용 데이터에 적용하여 예측값을 생성하시오

예측할 값(y) : price

평가 : RMSE(Root Mean Squared Error)

Data : train.csv, test.csv

제출 형식 : result.csv 파일

결측치, 범주형 변수 등은 적절히 처리할 것