

데이터 분석

■ 3유형

항목	statsmodels	scikit-learn
주요 목적	통계적 추론, 가설 검정, 해석	예측 성능, 머신러닝 파이프라인
출력	상세 통계 summary (p-value 등)	예측 중심 (간단한 score)
성능	중소규모 데이터에 적합	대규모 데이터, 고차원 데이터에 강함
Regularization	기본적으로 없음 (필요시 직접 구현)	Ridge, Lasso 등 기본 지원
시계열	강력 (ARIMA 등)	제한적
사용사례	학술 연구, 계량경제학, 보고서 작성	제품화, 예측 모델 배포

statsmodels 은 대규모 데이터셋에서는 scikit-learn이나 다른 라이브러리보다 느릴 수 있고, 최신 딥러닝/Gradient Boosting 모델은 지원하지 않는다

데이터 분석

■ 3유형

- `statsmodels`: 통계 모델링(statistical modeling)과 계량경제학(econometrics)에 특화된 오픈소스 패키지
- SciPy의 통계 기능을 보완하면서, R 언어의 통계 패키지처럼 통계적 추론(inference)과 해석(interpretation)에 중점을 둡니다
- 선형 회귀 모델: Ordinary Least Squares (OLS), Weighted Least Squares (WLS), Generalized Least Squares (GLS), Quantile Regression 등.
- 일반화 선형 모델 (GLM): Logistic, Poisson, Negative Binomial 등.
- 이산 선택 모델: Logit, Probit, Multinomial Logit.
- 시계열 분석: ARIMA, SARIMA, VAR, AR, Exponential Smoothing (Holt-Winters) 등
- 기타: ANOVA, Survival Analysis, Nonparametric methods, Robust regression 등
- 모델 적합 후 `summary()`를 호출하면 p-value, t-statistic, confidence interval, R-squared, AIC/BIC 등 상세한 통계 정보를 한 번에 제공

```
import statsmodels.api as sm
import statsmodels.formula.api as smf
```

데이터 분석

■ OLS (선형회귀)

- OLS(Ordinary Least Squares)는 최소제곱법을 이용한 선형회귀(Linear Regression) 모델
- 독립변수(X)를 이용해 종속변수(Y)의 평균을 가장 잘 설명하는 선형 모델을 찾는 것

```
import statsmodels.api as sm
import pandas as pd
# 데이터 준비
data = pd.read_csv('your_data.csv')
y = data['매출액'] # 종속변수 (연속형)
X = data[['광고비', '가격', '경쟁사수']] # 독립변수
# 상수항(constant) 추가 → 절편( $\beta_0$ )을 위해
X = sm.add_constant(X)
# OLS 모델 적합
model = sm.OLS(y, X)
result = model.fit()
# 결과 출력
print(result.summary())
```

데이터 분석

■ OLS (선형회귀)

광고비 지출이 매출액에 미치는 영향 분석
집의 크기, 방 개수, 위치 등이 집값에 미치는 영향
공부시간, 출석률, 과외여부가 시험 점수에 미치는 영향
경제 변수들을 이용한 GDP 예측

`add_constant()` : 회귀식 $y = \beta_0 + \beta_1x$ 에서 절편 β_0 추가

`result.summary()` 주요 해석 항목 :
R-squared : 설명력 (0~1). 높을수록 좋음. Adjusted R-squared도 함께 확인
coef : 회귀계수. x가 1단위 증가할 때 y의 평균 변화량
std err : 계수의 표준오차
Omnibus / Jarque-Bera잔차의 정규성 검정
Durbin-Watson잔차의 자기상관(독립성) 검정 (≈ 2 가 이상적)
Condition Number다중공선성(Multicollinearity) 경고 지표 (크면 문제)

데이터 분석

■ anova_lm()

- 분산분석(ANOVA) : 여러 그룹 간 평균의 차이가 통계적으로 유의미한지를 검정

```
from statsmodels.stats.anova import anova_lm  
  
model = smf.ols(  
    'score ~ group',  
    data=df  
) .fit()  
  
anova_lm(model)
```

PR(>F) #p-value 확인

4가지 서로 다른 교육 방법에 따른 학생들의 시험 점수 평균 차이 비교
A, B, C 세 브랜드 세탁기의 세척력(연속형) 비교
지역(서울/경기/부산/제주)별 평균 부동산 가격 비교
약물 투여량(저/중/고)과 성별(남/녀)에 따른 혈압 변화 (Two-way ANOVA)

데이터 분석

■ pairwise_tukeyhsd()

■ 사후검정

```
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import pandas as pd
# 데이터 예시
data = pd.DataFrame({
    'score': [85, 88, 90, 92, ..., 76, 79, 81], # 종속변수
    'method': ['A', 'A', 'A', ..., 'D', 'D', 'D'] # 독립변수 (그룹)
})
# ANOVA 후 Tukey HSD 수행
tukey = pairwise_tukeyhsd(endog=data['score'],
                           groups=data['method'],
                           alpha=0.05)
print(tukey)
```

5가지 서로 다른 광고 전략(A, B, C, D, E)에 따른 매출액 평균 비교
4가지 교육 방법에 따른 학생 성적 비교
6개 지역별 평균 집값 비교

→ 먼저 One-way ANOVA를 해서 전체적으로 차이가 있다는 결론이 나와야 Tukey HSD를 수행합니다.

데이터 분석

■ statsmodels.api.Logit()

- 이항 로지스틱 회귀(Binary Logistic Regression) 모델을 적합하는 클래스
- 종속변수가 0 또는 1로 이루어진 이진형(binary) 변수일 때 사용
- 독립변수들을 이용해 특정 사건이 발생할 확률을 예측하고, 각 변수의 영향을 분석합니다.
- 추정방법 : 최대우도법 (MLE)
- 계수 해석 : 로그오즈(Log-odds)
- 예측값 범위 : 0 ~ 1 (확률)

```
import statsmodels.api as sm
import pandas as pd
# 데이터 준비
data = pd.read_csv('your_data.csv')
y = data['합격여부'] # 0 또는 1
X = data[['나이', '학점', '토익', '인턴경험']] # 독립변수
# 상수항(constant) 추가 (필수!)
X = sm.add_constant(X)
# 모델 적합
model = sm.Logit(y, X)
result = model.fit()
# 결과 확인
print(result.summary())
```

데이터 분석

■ statsmodels.api.Logit()

- result.summary()에서 보는 주요 내용:
- Pseudo R-squared : 로지스틱 회귀에서는 일반 R^2 대신 McFadden의 Pseudo R^2 를 사용 (0~1, 높을수록 좋음)
- coef (계수) : 양수 $\rightarrow$ 독립변수가 증가할수록 사건 발생 확률 $\uparrow$
음수 $\rightarrow$ 독립변수가 증가할수록 사건 발생 확률 $\downarrow$
- 해석 :
Odds Ratio = $\text{np.exp}(\text{result.params})$
예: coef = 0.7 $\rightarrow$ Odds Ratio $\approx$ 2.01 $\rightarrow$ 해당 변수가 1단위 증가할 때 합격 오즈가 2.01배 증가
- p-value : < 0.05이면 해당 변수가 통계적으로 유의미
- LLR p-value (Likelihood Ratio Test) : 전체 모델이 유의한지 검정

고객이 상품을 구매할 확률 예측
환자가 특정 질병에 걸릴 확률 예측
지원자가 합격할 확률 예측
대출 연체 가능성 예측

데이터 분석

■ 3유형 -

- 주택가격 데이터(09.03.01.house_price.csv)를 이용하여 다중회귀분석을 수행하고 다음 물음에 답하시오. (종속변수는 price임)

- (1) 다중회귀분석을 수행하고, 모형의 F-통계량과 유의확률을 구하시오.
- (2) 유의수준 0.05 기준으로 유의한 독립변수의 개수를 구하시오.
- (3) 결정계수(R-squared)가 가장 높은 독립변수 2개의 조합을 구하시오.

변수	설명	변수유형
house_id	주택ID	수치형
area	평수	수치형
floor	층수	수치형
built_year	건축연도	수치형
subway_distance	지하철역까지 거리(m)	수치형
price	매매가격	수치형

데이터 분석

■ 3유형 -

- 다음은 보험 청구 데이터(09.03.02.insurance_claim.csv)다. 이 데이터를 이용하여 로지스틱 회귀분석을 수행하시오. (종속변수는 보험청구여부임)

1) 로지스틱 회귀분석을 수행하고, 모형의 카이제곱 통계량과 유의확률을 구하시오.

(2) 유의수준 0.05 기준으로 유의한 독립변수의 개수를 구하시오.

(3) 혈압(bp)과 혈당(glucose)이 증가할 때의 오즈비(odds ratio)를 구하시오.

변수	설명	변수유형
age	연령, 20~70세	수치형
bmi	체질량지수(Body Mass Index)	수치형
bp	혈압(blood pressure)	수치형
glucose	혈당	수치형
claim	보험청구여부	범주형

데이터 분석

■ 3유형 -

- 고객 이탈지수를 종속변수로 하여, 로지스틱 회귀를 수행하고, 관련된 분석을 진행하시오.
(1)주어진 데이터(08.03.01.customer_churn.csv)에서 상수항을 추가한 로지스틱 회귀를 수행하고, 유의하지 않은 변수의 개수를 구하시오.
(2)유의미한 변수만을 독립변수로 하여, 로지스틱 회귀를 다시 수행하시오. 이때 회귀계수의 평균을 구하시오.
(3) 위 (1), (2)에서 얻은 회귀식을 바탕으로 calls 변수가 5 증가할 때 오즈비는 몇 배 증가하는지 구하시오.

변수	설명	변수유형
age	고객의 나이	수치형
gender	고객의 성별 (Male/Female)	범주형
calls	고객의 월간 통화량 (건/월)	수치형
internet_usage	인터넷 사용 시간 (시간/일)	수치형
monthly_charge	월 요금 (달러)	수치형
customer_support_calls	고객지원 센터에 전화한 횟수	수치형
contract_length	계약 기간 (월)	수치형
data_usage	데이터 사용량 (GB/월)	수치형
sms_usage	SMS 사용량 (건/월)	수치형
payment_method	결제 방법 (Credit Card/Bank Transfer/PayPal)	범주형
region	고객의 거주 지역 (North/South/East/West)	범주형
churn	고객 이탈 여부 (0: 유지, 1: 이탈)	이진형(Y)

데이터 분석

■ 3유형 -

- 다음은 PIQ(Performance IQ)를 예측하기 위한 다양한 독립변수들을 포함한 데이터셋 (08.03.02.piq.csv)이다. 이 데이터를 바탕으로 다중선형회귀 분석을 수행하여 다음 질문에 답하시오.
- (1)다중선형회귀분석을 적용하여 각 독립변수의 회귀계수를 구하고, 가장 유의미한 변수의 회귀계수를 쓰시오.
- (2)Test Data를 이용하여 결정계수 (R^2) 값을 구하시오.
- (3)아래와 같은 참가자 데이터가 주어졌을 때, 다중선형회귀식을 사용하여 각 참가자의 PIQ를 예측하시오.

변수	설명	변수유형
PIQ	수행 지능지수 (Performance IQ)	수치형
brain_size	뇌 크기	수치형
height	키 (cm)	수치형
weight	몸무게 (kg)	수치형
education_level	교육 수준 (1: 고등학교, 2: 대학교, 3: 대학원)	범주형
reading_habits	독서 습관 (0: 없음, 1: 1시간 이하, 2: 1시간 이상)	범주형
age	나이 (연령)	수치형

데이터 분석

■ 3유형 -

- 키(Height), 몸무게(Weight), 발사이즈(ShoeSize)를 이용하여 남녀(Sex) 성별을 분류하는 로지스틱 회귀모형을 만들고자 한다. 주어진 데이터셋(07.03.01-gender_prediction_dataset.csv)를 이용하여 로지스틱 회귀모형을 만들고 아래의 질문에 답하시오. 단, 주어진 데이터셋의 2/3를 훈련용으로, 1/3을 테스트용으로 분할하여 작업하시오.
- (1) 훈련용 데이터를 이용하여 'Height', 'Weight', 'ShoeSize'를 설명변수로 사용하는 로지스틱 회귀 모형을 만들고 Weight의 오즈비를 계산하시오.
- (2) 모델의 로짓우도(log-likelihood)를 구하시오.
- (3) 위 (2)에서 만든 모델로 평가용 데이터를 예측한 결과와 실제값의 오차율을 구하시오. (소수 네자리에서 반올림)

데이터 분석

■ 3유형 -

- 중고차의 가격을 다중회귀분석으로 분석하고자 한다. Price를 종속변수로하며 'year', 'transmission', 'mileage', 'fuelType', 'tax', 'mpg', 'engineSize'를 독립변수로 사용한다. 데이터의 구성은 아래 표와 같다. (07.03.02-used_car_price_dataset.csv)

- (1) 다중회귀분석 모형의 결정계수를 구하시오.
- (2) 독립변수 중 회귀계수가 가장 큰 변수와 값을 구하여 튜플 타입으로 출력하시오.
(ex. ('Weight', 0.09003569454430438))
- (3) 독립변수 중 p-value가 가장 낮은 변수와 값을 구하여 튜플 타입으로 출력하시오.

변수	설명
year	생산년도
tranmission	트랜스미션(Manual, Automatic, Semi-Auto)
mileage	주행거리
fueltype	연료타입 (Petrol, Diesel, Hybrid)
tax	세금
mpg	연비
engineSize	엔진크기
Price	가격 (\$)

표 4 : 중고차 가격 데이터 세트 변수 설명